

UNIVERSIDADE VILA VELHA

ÍCARO ARAÚJO BARROS

TRADUÇÃO AUTOMATIZADA PARA DOCUMENTOS
JURÍDICOS:
UM SISTEMA BASEADO EM INTELIGÊNCIA ARTIFICIAL

VILA VELHA
2024

ÍCARO ARAÚJO BARROS

TRADUÇÃO AUTOMATIZADA PARA DOCUMENTOS
JURÍDICOS:
UM SISTEMA BASEADO EM INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso submetido à Universidade Vila Velha, como requisito necessário para obtenção do grau de Bacharel em Ciência da Computação

Vila Velha, 12 de agosto de 2025

UNIVERSIDADE VILA VELHA

ÍCARO ARAÚJO BARROS

Esta Monografia foi julgada adequada para a obtenção do título de Bacharel em
Ciência da Computação, sendo aprovada em sua forma final pela banca examinadora:

Orientador(a): Prof. Dr. Jean-Rémi Bourguet
Universidade Vila Velha - UVV

Prof. Dr. Emerson Scheidegger
Universidade Vila Velha - UVV

Vila Velha, 12 de agosto de 2025

Agradecimentos

ou Acknowledgements, se em inglês

Opcional

Resumo

Este trabalho propõe uma prova de conceito para um sistema de tradução automatizada de documentos jurídicos digitalizados, baseado em inteligência artificial. O sistema utiliza técnicas de Processamento de Linguagem Natural (PLN) para interpretar a complexidade da linguagem forense. À medida que processa um número crescente de documentos, o sistema evolui, tornando-se progressivamente mais adaptado às nuances linguísticas e ao jargão judiciário, o que permite traduções mais precisas e contextualmente adequadas, em contraste com tradutores convencionais que tendem a literalismos.

O principal problema abordado é a acessibilidade e a disseminação internacional de documentos jurídicos brasileiros, facilitando a tradução de conteúdos altamente técnicos e tornando-os acessíveis para um público mais amplo. Aproximadamente 260 milhões de pessoas falam português no mundo, com uma porcentagem significativa fora do Brasil, tornando a tradução de documentos legais uma ferramenta valiosa para a compreensão do sistema jurídico brasileiro em um contexto global. A tradução automatizada por meio de um sistema PLN, com grau elevado de compreensão contextual, pode também ser reaproveitada e aplicada em diversos cenários onde a linguagem se distancia do uso cotidiano ou das definições de dicionário. Dessa forma, esse sistema se torna uma aliada crucial na interpretação precisa de diferentes linguagens, promovendo uma comunicação mais eficaz em contextos especializados. Para a implementação do sistema, ferramentas como Python e bibliotecas de PLN foram utilizadas.

Palavras-chave: tradução automática, inteligência artificial, documentos jurídicos, processamento de linguagem natural, acessibilidade, python.

Abstract

This paper proposes a proof of concept for an automated translation system for digitized legal documents, based on artificial intelligence. The system employs Natural Language Processing (NLP) techniques to interpret the complexity of legal vocabulary. As it processes an increasing number of documents, the system evolves, progressively adapting to linguistic nuances and legal jargon, which enables more precise and contextually appropriate translations, in contrast to conventional translators that tend to resort to literalism.

The primary issue addressed is the accessibility and international dissemination of Brazilian legal documents, facilitating the translation of highly technical content and making it accessible to a broader audience. Approximately 260 million people speak Portuguese worldwide, with a significant percentage residing outside Brazil, making the translation of legal documents a valuable tool for understanding the Brazilian legal system in a global context. Automated translation through an NLP system, with a high degree of contextual understanding, can be reused and applied in various scenarios where language diverges from everyday use or dictionary definitions. In this way, the system becomes a crucial ally in the precise interpretation of different languages, promoting more effective communication in specialized contexts. Python and NLP libraries were utilized for the implementation of the system.

Keywords: automated translation, artificial intelligence, legal documents, natural language processing, accessibility, python.

Lista de ilustrações

Figura 1 – Árvore sintática	21
Figura 2 – Diagrama de Implantação do Sistema de Tradução Automática	34
Figura 3 – Diagrama de Classes do Sistema de Tradução Automática	35

Lista de abreviaturas e siglas

Lista de Siglas

<i>NLP</i>	<i>Natural Language Processing</i> , ou Processamento de Linguagem Natural.
<i>MT</i>	<i>Machine Translation</i> , ou Tradução de Máquina.
<i>TM</i>	<i>Transformer Model</i> , ou Modelo Transformador.
<i>ML</i>	<i>Machine learning</i> , ou Aprendizado de Máquina.
<i>ML</i>	<i>Application Programming Interface</i> , ou Interface de Programação de Aplicação.
<i>BLEU</i>	<i>BiLingual Evaluation Understudy</i> , ou Avaliação Bilingue Substitutiva.
<i>WER</i>	<i>Word Error Rate</i> , ou Taxa de Erro por Palavra.
<i>PER</i>	<i>Position-independent word Error Rate</i> , ou Taxa de Erro por Palavra Independente de Posição.
<i>TER</i>	<i>Translation Error Rate</i> , ou Taxa de Erro de Tradução.

Sumário

1	INTRODUÇÃO	17
1.1	Problemática	17
1.2	Justificativa	18
1.3	Objetivo	18
1.3.1	Objetivo geral	18
1.3.2	Objetivos específicos	18
1.4	Metodologia	19
1.5	Organização	19
2	REVISÃO DA LITERATURA	21
2.1	Arquiteturas de sistemas de tradução automática	21
2.1.1	Abordagem direta	21
2.1.2	Abordagem baseada em transferência	21
2.1.3	Abordagem Interlingua	22
2.2	A Importância da tradução de máquina para o contexto jurídico	22
2.2.1	Percepção do uso de MT e riscos no contexto jurídico	22
2.2.2	Aplicações práticas já aceitas de MT no contexto jurídico	23
2.3	Avaliação da tradução automática	23
2.3.1	Métricas quantitativas de avaliação de MT	24
2.3.2	Nuances na avaliação da eficácia da MT no contexto jurídico	24
3	METODOLOGIA	27
3.1	Processamento de linguagem natural e a evolução da tradução automática	27
3.2	Problemáticas clássicas de tradução jurídica	27
3.2.1	Termos com significados diferentes em jurisdições distintas	27
3.2.2	Diferenças conceituais para termos iguais	28
3.3	Tecnologia e ferramentas utilizadas	28
3.4	Métricas de avaliação	28
3.5	Treinamento e validação do modelo	29
4	PROPOSTA	31
4.1	Arquitetura do projeto	31
4.1.1	Coleta de dados	31
4.1.2	Pré-processamento dos dados	31
4.1.3	Modelagem e treinamento do modelo de tradução	32

4.1.4	Avaliação do modelo	32
4.2	Avaliação qualitativa com especialistas	32
4.3	Visões da arquitetura e diagramas	33
4.3.1	Visão de requisitos	33
4.3.2	Visão de implantação	33
4.3.3	Visão lógica	35
5	CONCLUSÃO	37
	REFERÊNCIAS	39

1 Introdução

No cenário atual de globalização, o acesso à informação legal transcende as fronteiras nacionais, permitindo que indivíduos e comunidades possam entender e interagir com sistemas jurídicos estrangeiros. O acesso a documentos legais traduzidos é essencial para garantir que cidadãos, imigrantes, estudantes e profissionais do direito possam compreender seus direitos e deveres em diferentes jurisdições, sem depender exclusivamente de tradutores especializados. A tradução de documentos jurídicos, portanto, assume um papel crucial na promoção da acessibilidade à justiça e na construção de pontes de entendimento entre diferentes culturas e legislações.

No entanto, a tradução jurídica não é uma tarefa trivial, pois envolve nuances que vão além da simples conversão linguística. O sistema jurídico carrega consigo terminologias específicas, que podem ter interpretações e implicações diferentes dependendo do contexto, ou então palavras onde o significado difere em uso cotidiano. A tradução precisa não apenas transmitir o conteúdo literal, mas também o contexto e a intenção das disposições legais, o que é particularmente importante para evitar mal-entendidos que possam resultar em consequências legais.

Diante desse contexto, surge a necessidade de desenvolver sistemas de tradução automática que sejam capazes de lidar com as particularidades da linguagem jurídica, capturando as nuances culturais e legais inerentes a cada assunto legal. Este trabalho propõe o desenvolvimento de um sistema de tradução automática baseado em Processamento de Linguagem Natural, focado na tradução de documentos jurídicos entre o português e o inglês. O objetivo é criar um modelo que não apenas traduza termos e frases, mas que também interprete o contexto legal e cultural, garantindo que o significado e as implicações legais sejam corretamente transmitidos na língua alvo.

1.1 Problemática

Apesar das inovações em tradução automática, a complexidade da linguagem judicial e as sutilezas culturais continuam a ser desafios substanciais. A questão central que este trabalho busca abordar é: **como a tecnologia de Processamento de Linguagem Natural (NLP) pode efetivamente capturar e refletir as nuances culturais e legais, ao traduzir documentos jurídicos?**. As implicações éticas e legais da tradução inadequada de termos críticos ressaltam a necessidade de um enfoque mais refinado e consciente na tradução automática de documentos jurídicos.

Além disso, o acesso a documentos legais brasileiros traduzidos do português

apresenta uma problemática própria. A legislação brasileira frequentemente utiliza um vocabulário vasto, repleto de sinônimos e expressões que podem ter significados semelhantes, mas que carregam conotações distintas. Essa riqueza lexical, embora seja um reflexo da diversidade e da riqueza cultural do idioma, pode complicar a tarefa de tradução. Palavras que têm o mesmo significado semântico podem ser escolhidas com base em nuances específicas que variam conforme o contexto jurídico, a tradição legal e as expectativas culturais.

A linguagem utilizada nos documentos jurídicos muitas vezes se caracteriza por um jargão técnico e uma formalidade que pode tornar a interpretação e a tradução ainda mais desafiadoras. O uso de uma norma culta que pode beirar o arcaico não só dificulta a compreensão para aqueles que não estão familiarizados com o contexto legal, mas também impõe uma expectativa cultural que pode ser difícil de replicar em outra língua.

1.2 Justificativa

A crescente quantidade de documentos jurídicos disponíveis online, aliada à necessidade de acesso a informações legais em um contexto global, torna urgente o desenvolvimento de soluções de tradução que considerem as especificidades culturais. A tradução automática não apenas facilita o acesso à informação, mas também desempenha um papel crucial na promoção da justiça e da equidade no acesso a direitos legais. Portanto, investigar e implementar métodos que melhorem a sensibilidade cultural nas traduções automáticas é uma contribuição valiosa para ambos os campos da tradução e do direito.

1.3 Objetivo

1.3.1 Objetivo geral

Desenvolver um sistema de tradução automática baseado em Processamento de Linguagem Natural (NLP) que capture e reflita as nuances culturais e legais na tradução de documentos jurídicos entre o português e o inglês.

1.3.2 Objetivos específicos

Considerando o desenvolvimento do trabalho e o objetivo geral apresentado, destacam-se os seguintes objetivos específicos:

- Pesquisar sobre as dificuldades e nuances presentes na tradução de documentos jurídicos entre o português e o inglês;

- Levantar exemplos de termos jurídicos que apresentam nuances na tradução e suas implicações legais;
- Realizar testes de tradução utilizando um conjunto de dados que represente documentos jurídicos em português e suas traduções para o inglês;
- Analisar a eficácia do sistema de tradução em capturar nuances culturais e legais, comparando as traduções automáticas com traduções realizadas por profissionais;
- Publicar os resultados e contribuir para a discussão sobre a importância da precisão na tradução de textos jurídicos.

1.4 Metodologia

A metodologia deste trabalho consiste em primeiramente, uma pesquisa exploratória e aplicada, que busca entender as nuances da linguagem jurídica e desenvolver um sistema de tradução automática.

A seguir, o desenvolvimento do sistema de tradução envolverá a seleção de um dataset com documentos jurídicos em português e suas traduções correspondentes para o inglês. Utilizando técnicas de NLP, o sistema será treinado para reconhecer e traduzir termos jurídicos, levando em consideração as nuances culturais.

Serão realizados testes de validação, onde as traduções automáticas serão comparadas com traduções humanas, a fim de avaliar a precisão e a eficácia do sistema. A análise dos resultados permitirá identificar áreas de melhoria e as contribuições do sistema para a tradução de documentos jurídicos.

1.5 Organização

O presente trabalho está organizado da seguinte forma:

Capítulo 2: Revisão da Literatura de trabalhos relacionados, abordando os conceitos fundamentais da Tradução de Máquina e aplicações em contexto jurídico.

Capítulo 3: Discute os métodos e técnicas de NLP aplicáveis à tradução automática, desenvolvendo estudos de caso e incluindo a modelagem do sistema.

2 Revisão da Literatura

2.1 Arquiteturas de sistemas de tradução automática

A Tradução de Máquina (MT), que consiste na conversão de uma língua de origem para uma língua alvo de forma mecânica, evoluiu significativamente ao longo dos anos. Entre as principais arquiteturas de sistemas de tradução automática discutidas na literatura, destacam-se: Abordagens diretas, baseada em transferência e Interlingua (Chérargui, 2012).

2.1.1 Abordagem direta

A abordagem direta realiza a tradução diretamente da língua de origem para a língua alvo. Nessa arquitetura, o sistema analisa o vocabulário da língua de origem para resolver ambiguidades e identificar a ordem correta das palavras na língua alvo. Um dicionário bilíngue e programas de análise léxica e morfológica são fundamentais para esta abordagem (Chérargui, 2012, p. 163)

2.1.2 Abordagem baseada em transferência

A abordagem de transferência utiliza três etapas principais para realizar a tradução. Primeiramente, o texto na língua de origem é convertido em uma representação intermediária; em seguida, essa representação é transformada para uma estrutura equivalente na língua alvo. Por fim, a tradução final é gerada a partir dessa estrutura (Chérargui, 2012). A representação intermediária pode variar de uma árvore sintática (Figura 1) até uma representação mais semântica, dependendo da complexidade e dos requisitos linguísticos.




Figura 1 – Árvore sintática

<i>F</i> : Frase	<i>SN</i> : Sintagma Nominal
<i>SV</i> : Sintagma Verbal	<i>V</i> : Verbo
<i>Q</i> : Quantificador	<i>N</i> : Nome

2.1.3 Abordagem Interlingua

Considerada ideal para sistemas multilíngues, a abordagem Interlingua realiza a análise do texto de origem, extraíndo seu conteúdo semântico e o representando em uma linguagem neutra ("Interlingua") e independente das línguas de origem e destino. Posteriormente, o conteúdo é traduzido para a língua alvo a partir dessa representação neutra, permitindo o uso de uma mesma análise para múltiplas línguas de origem e destinos variados (Chérargui, 2012, p. 164)

2.2 A Importância da tradução de máquina para o contexto jurídico

Como discutido anteriormente, a estrutura sintática de uma frase e a maneira como diferentes elementos se conectam desempenham um papel fundamental na tradução automática. No entanto, a precisão na tradução se torna ainda mais complexa em contextos que exigem uma interpretação rigorosa e sensível a nuances, como o contexto jurídico.

2.2.1 Percepção do uso de MT e riscos no contexto jurídico

De acordo com Vieira, O'Hagan and O'Sullivan (2021), a percepção sobre os riscos associados ao uso de MT no setor jurídico varia significativamente (Vieira; O'Hagan; O'Sullivan, 2021, p. 1522).

Por exemplo, o Tribunal Estadual do Novo México, nos EUA, se destaca por ter estabelecido diretrizes claras em relação ao uso de MT, por conta de sua frequente circunstância de apontar jurados não fluentes em inglês. Segundo essas diretrizes, traduções feitas por MT que não forem editadas por um humano não devem ser utilizadas em documentos formais, como procedimentos judiciais ou provas (Chávez, 2008, p. 323)

Evidenciado ainda por Vieira, O'Hagan and O'Sullivan (2021), há em contrapartida, evidências que sugerem uma alta confiança para com a tradução automática, que demonstra para os autores, uma demonstração de falta de conscientização entre profissionais sobre os riscos de MT (Vieira; O'Hagan; O'Sullivan, 2021, p. 1522). No caso jurídico de Ernesto Vasquez, em Dallas - Texas, um prisioneiro federal de língua espanhola tentou retirar uma confissão alegando que não compreendeu adequadamente a situação devido a traduções deficientes oferecidas por seu advogado. Curiosamente, o novo advogado que defendeu a retirada da confissão criticou o trabalho do colega anterior, mencionando o Google Translate como uma fonte viável: *"Se eu não conheço a palavra, meritíssimo, eu procuro a tradução. Está disponível gratuitamente no Google. Existe um aplicativo chamado Google Translate"*¹. Em outro exemplo, o próprio tribunal recorreu ao uso de MT: *"Como os Requerentes não forneceram tradução para nenhum dos documentos em polonês submetidos*

¹ Vasquez vs USA. 2019. Disponível em: <https://scholar.google.co.uk/scholar_case?case=4394896296660864715&hl=pt-BR&as_sdt=0>

em apoio à sua petição, o Tribunal usou o serviço gratuito Google Translate para confirmar certas declarações”².

Esses exemplos indicam que, apesar dos avanços tecnológicos, a MT ainda apresenta riscos significativos para o setor jurídico, especialmente em situações onde a precisão e a compreensão contextual são fundamentais.

2.2.2 Aplicações práticas já aceitas de MT no contexto jurídico

Nem todo uso de MT é mal-visto. Segundo Vieira, O’Hagan and O’Sullivan (2021), em fases de pré-julgamento, como a etapa de descoberta — em que as partes trocam evidências e informações legais —, o risco de usar MT é considerado menor. Nesse contexto, a MT pode atuar como uma ferramenta inicial de triagem para revisão rápida de informações eletronicamente disponíveis, facilitando a identificação de documentos relevantes para análise subsequente por tradutores profissionais (Foster and Northrop (2011), p. 45; Nelson and Simek (2017), p. 19)

Além disso, o uso de MT em traduções de patentes representa outra aplicação comum e relativamente aceita. O Manual de Procedimentos de Exame de Patentes do Escritório de Patentes e Marcas dos Estados Unidos permite que examinadores usem MT como suporte em decisões de rejeição de patentes. *"Se um documento utilizado pelo examinador para justificar uma rejeição estiver em um idioma diferente do inglês, uma tradução deve ser obtida para que o registro seja claro quanto aos fatos precisos nos quais o examinador baseia sua rejeição. [...] A tradução pode ser uma tradução automática ou um equivalente em inglês do documento não escrito em inglês"* ³.

2.3 Avaliação da tradução automática

Até o momento, discutimos as abordagens e implicações da tradução de máquina (MT) em diferentes contextos, incluindo o jurídico, onde os requisitos de precisão e contexto são críticos. No entanto, avaliar a qualidade e confiabilidade de uma tradução gerada automaticamente é uma tarefa complexa e multifacetada. Nesta seção, apresentamos as principais métricas de avaliação de MT e os desafios específicos associados ao uso de MT no setor jurídico.

² Super Express USA Publishing Corp. vs Spring Publishing Corp. 2017. Disponível em: <<https://casetext.com/case/super-express-us-publ-g-corp-v-spring-publ-g-corp>>

³ USPTO - United States Patent and Trademark Office. 2018. Disponível em: <<https://mpep.uspto.gov/RDMS/MPEP/current#/current/d0e122292.html>>

2.3.1 Métricas quantitativas de avaliação de MT

Um dos métodos mais utilizados para avaliar a tradução automática envolve métricas quantitativas, que comparam a tradução gerada pelo sistema com traduções de referência. Segundo Chérargui (2012), as métricas mais comumente empregadas incluem:

- **BLEU (*BiLingual Evaluation Understudy*)**: Desenvolvida por Papineni em 2001, essa métrica mede a similaridade entre a tradução da máquina e traduções de referência feitas por humanos, penalizando traduções mais curtas com o fator de penalidade de brevidade. BLEU é amplamente aceita como uma métrica objetiva definido por uma fórmula matemática que determina um fator de similaridade em n-grama (Chérargui, 2012, p. 167).
- **WER (*Word Error Rate*)**: Proposta por Popovic e Ney em 2007, esta métrica calcula a distância de Levenshtein entre a tradução hipotética, feita pela máquina, e a referência, feita por um humano. Essa métrica então considera inserções, deleções e substituições necessárias para igualar as traduções. WER não permite a reorganização de palavras, limitando sua aplicabilidade em frases onde a tradução da hipótese pode ser correta, porém com ordem gramatical diferente da tradução referencial (Chérargui, 2012, p. 167). Este tipo de rigidez quanto a flexibilidade a ordem das palavras se dá ao fato de que WER tem seu foco no reconhecimento de fala, não apenas de tradução em máquina.
- **PER (*Position-independent word Error Rate*)**: A PER foi proposta anterior a WER, em 1997. Esta métrica compara as palavras feitas pela tradução de máquina, com as palavras da tradução referencial, não levando consideração a ordenação das palavras. A PER, portanto, falha em reconhecer traduções corretas onde a ordem semântica muda, mudando o sentido semântico de uma tradução (Chérargui, 2012, p. 168).
- **TER (*Translation Error Rate*)**: Proposta subsequente a PER, em 2006, TER propõe-se a medir o número mínimo de edições para transformar a tradução da máquina em uma referência, incluindo inserção, deleção e substituição de palavras e até a movimentação de sequências de palavras. Sendo assim, uma métrica mais flexível, porém que põe em evidência vulnerabilidade quanto a manutenção contextual de uma frase. (Chérargui, 2012, p. 168).

2.3.2 Nuances na avaliação da eficácia da MT no contexto jurídico

Vieira, O'Hagan and O'Sullivan (2021) apontam as dificuldades práticas na avaliação da MT em textos jurídicos. Eles destacam que as avaliações anteriores muitas vezes negligenciam a natureza dependente de contexto e subjetiva da qualidade da tradução,

conforme observado por Somers (2007). Somers também nota que variáveis como o comprimento das frases influenciam a contagem de erros, o que pode distorcer a avaliação da MT, já que um erro em uma frase curta pode ser proporcionalmente mais grave do que múltiplos erros em uma frase longa.

Wahler (2018) sugere estabelecer requisitos mínimos de precisão como medida para reduzir riscos na utilização de MT em contextos legais, mas Vieira, O'Hagan and O'Sullivan (2021) ressaltam as dificuldades práticas, dado que a precisão depende tanto da complexidade do texto original quanto do método de avaliação utilizado. Contudo, os autores advertem contra a dependência exclusiva em métricas automáticas, que, conforme (Callison-Burch; Osborne; Koehn, 2006), são limitadas, trazendo erros comuns que poderiam ser evitados dada a intervenção feita por uma avaliação humana. *"De forma mais ampla, declarações como essas desconsideram a natureza superficial das métricas automáticas e o fato de que, na prática, são medidas de similaridade que não levam em conta o efeito real ou a gravidade de quaisquer erros"* (Vieira; O'Hagan; O'Sullivan, 2021)

3 Metodologia

3.1 Processamento de linguagem natural e a evolução da tradução automática

Neste capítulo, detalharemos a metodologia utilizada para desenvolver e avaliar um sistema de tradução automática (MT) voltado para a tradução jurídica, considerando as nuances culturais e legais. Utilizando Processamento de Linguagem Natural (NLP) e técnicas de aprendizado profundo, buscamos abordar as dificuldades específicas da tradução jurídica com o apoio de avaliações realizadas por humanos para refinar o sistema.

A metodologia adotada visa minimizar as limitações comuns nas traduções jurídicas automatizadas, como a interpretação incorreta de termos ambíguos e a falta de compreensão do contexto cultural e legal. Nosso objetivo é criar um modelo de NLP que não apenas traduza palavras, mas que também compreenda o significado subjacente dos termos e suas implicações jurídicas.

3.2 Problemáticas clássicas de tradução jurídica

Para enfrentar os desafios específicos da tradução jurídica, estrutura-se a problemática em dois tipos principais de dificuldades de tradução:

3.2.1 Termos com significados diferentes em jurisdições distintas

Esse problema ocorre quando dois sistemas legais utilizam palavras com conotações semânticas semelhantes, mas que entre duas línguas diferentes, possuem estrutura sintática completamente diferente, ainda mais fora de contexto. Por exemplo, no Brasil, o termo *calção* refere-se a um valor monetário que assegura o cumprimento de um contrato, geralmente em contexto imobiliário. Já nos Estados Unidos, a palavra *consideration* cumpre uma função similar, mas possui implicações próprias do direito norte-americano, como a garantia de um contrato por meio de um penhor de valor. Este estudo busca treinar o modelo para identificar tais termos, com auxílio de uma etiquetagem ontológica do meio em que se identifica essas palavras, para refletir adequadamente as nuances de cada contexto legal.

3.2.2 Diferenças conceituais para termos iguais

Neste caso, a problemática se refere a termos idênticos que possuem interpretações e limitações legais variadas entre jurisdições. Um exemplo claro é o conceito de *liberdade de expressão*, que na Constituição Americana é considerado um direito absoluto garantido pela Primeira Emenda. Em contraste, no Brasil, esse direito é defendido até o ponto em que não infrinja a liberdade de terceiros, o que implica uma limitação na interpretação desse termo. Considerando tais diferenças, a metodologia proposta inclui um mapeamento dessas limitações legais para que o sistema possa reconhecer estes termos, e **adicionar** contexto para refletir as nuances do assunto.

3.3 Tecnologia e ferramentas utilizadas

Para desenvolver o sistema de tradução automática, utilizamos a linguagem de programação Python em conjunto com bibliotecas de aprendizado profundo, como *TensorFlow* e *PyTorch*, que facilitam o treinamento de modelos complexos de NLP. Essas bibliotecas permitem a manipulação de grandes quantidades de dados textuais e o desenvolvimento de redes neurais capazes de identificar padrões de linguagem e contexto.

Para a criação e avaliação do modelo, usamos conjuntos de dados de documentos jurídicos em português e inglês, representativos das diferenças culturais e linguísticas discutidas anteriormente. Esses dados serão processados para treinar o modelo com foco em identificar as nuances jurídicas, permitindo que ele compreenda as diferenças conceituais e contextuais entre termos semelhantes nas duas línguas.

3.4 Métricas de avaliação

A avaliação do sistema de tradução automática será realizada com a métrica BLEU (*BiLingual Evaluation Understudy*), que mede a precisão de traduções baseando-se na similaridade entre a tradução gerada pelo sistema e traduções de referência realizadas por humanos. Esta métrica considera o alinhamento de n-gramas, o que permite avaliar a presença de termos corretos e de sequências de palavras que preservam o contexto do texto de origem. A métrica BLEU, se assemelha a análise de verdadeiro-positivo e falso-positivo, que nos permite identificar os casos em que o modelo acerta a tradução de forma contextual e aqueles em que a tradução se distancia do significado original.

Dessa forma, a métrica BLEU servirá para verificar a fidelidade do sistema em relação às traduções humanas, considerando as peculiaridades do contexto jurídico. Além disso, realizaremos análises qualitativas para identificar onde o sistema falha e onde acerta em capturar as nuances culturais e legais do texto.

3.5 Treinamento e validação do modelo

O treinamento do modelo foi dividido em etapas, incluindo a fase inicial de pré-processamento dos dados, onde os documentos jurídicos foram organizados e categorizados de acordo com seus contextos legais. A fase de treinamento do modelo utiliza *embedding layers* e Modelos Transformadores (TM), que são redes neurais adequadas para capturar as relações de dados sequenciais, ou seja, contextualização.

Após o treinamento inicial, realizamos a validação cruzada utilizando amostras de textos que não foram incluídas no conjunto de treinamento. A validação permitirá identificar a capacidade do modelo de lidar com termos específicos do jargão jurídico e adaptar-se aos dois tipos de problemas previamente definidos. Eventualmente, ajustes finos serão realizados no modelo, a partir de opiniões experts do domínio jurídico, para aprimorar sua capacidade de reconhecer e refletir nuances contextuais e culturais.

Com essa abordagem metodológica, o sistema de tradução automática se propõe a ser uma ferramenta útil para a tradução jurídica, oferecendo um suporte que considera as especificidades e os desafios da área. Os resultados obtidos e as análises dos testes serão apresentados nos próximos capítulos, abordando os pontos fortes e as limitações do sistema proposto.

4 Proposta

Neste capítulo, apresentaremos a proposta de arquitetura para o sistema de tradução automática de documentos jurídicos. A proposta inclui desde a coleta de dados até o treinamento e avaliação do modelo de tradução baseado em Processamento de Linguagem Natural (NLP).

4.1 Arquitetura do projeto

4.1.1 Coleta de dados

Para este projeto, será utilizado um conjunto de dados proveniente de uma coletânea de documentos legislativos do estado do Espírito Santo, incluindo metadados que se referem a como o documento seria organizado de forma ontológica, ou seja, características que se tornam relevantes para a avaliação do contexto do arquivo. Portanto, arquivos contêm anotações e informações que facilitam a organização e catalogação dos textos, classificando-os em categorias que englobam áreas temáticas e conceitos jurídicos específicos. Essa catalogação ontológica auxiliará o modelo a reconhecer contextos, ajudando na interpretação de termos com significados complexos e específicos ao meio legislativo.

A coleta de dados será realizada por meio de uma API conectada a essa base legislativa, permitindo o acesso a uma variedade de documentos e metadados associados. Esse processo possibilita a criação de uma base de dados robusta e variada, que reflete as diferentes nuances e terminologias do direito brasileiro.

4.1.2 Pré-processamento dos dados

Os documentos coletados passarão por uma fase de pré-processamento, onde serão normalizados e organizados para o treinamento do modelo. Esse pré-processamento inclui:

- **Limpeza de texto:** remoção de caracteres especiais e formatação inadequada.
- **Tokenização dos documentos:** transformação do texto em uma sequência de tokens que o modelo pode processar.
- **Inserção dos metadados em RDF:** integração ao triple store para ajudar na contextualização semântica durante o treinamento.

4.1.3 Modelagem e treinamento do modelo de tradução

Para o treinamento do modelo de tradução, será utilizada uma arquitetura de aprendizado profundo com técnicas avançadas de NLP, tais como *embeddings* (representações do texto em formato de objeto) e Modelos Transformadores (TM), comumente aplicados em tarefas de tradução automática (preferencialmente, modelos pré-treinados com capacidade de processar traduções de uso coloquial). A estrutura principal envolve:

- ***Embedding Layer***: onde as palavras dos documentos legislativos serão convertidas em vetores numéricos, permitindo ao modelo identificar similaridades entre termos e contextos semânticos.
- ***Transformer Model***: estrutura que permite capturar dependências contextuais em grandes volumes de texto, particularmente útil para interpretar frases complexas e jargões técnicos do meio jurídico.

Durante o treinamento, o modelo será alimentado com amostras de documentos e suas traduções de referência para ajustar seus parâmetros e melhorar sua precisão.

4.1.4 Avaliação do modelo

Após o treinamento, o modelo será submetido a uma fase de avaliação. Utilizaremos tanto métricas quantitativas, como BLEU, quanto avaliações qualitativas conduzidas por profissionais da área de advocacia, que realizarão uma comparação entre a tradução feita pelo modelo e traduções obtidas por outras ferramentas, como o Google Translate. A avaliação qualitativa permitirá medir a adequação da tradução em termos de precisão e preservação das nuances culturais e legais.

4.2 Avaliação qualitativa com especialistas

Para garantir a eficácia do modelo em capturar as nuances jurídicas, uma fase de avaliação qualitativa será realizada com profissionais de direito. Nessa fase, os avaliadores receberão as traduções do modelo proposto, juntamente com traduções de sistemas de tradução automatizada amplamente utilizados, como *Google Translate*, para avaliar a qualidade e adequação da tradução em um contexto real. Essa análise comparativa permitirá identificar pontos fortes e limitações do modelo, oferecendo também uma comparação para aprimoramentos futuros.

A proposta, como apresentada, visa desenvolver uma solução que vá além da tradução literal, focando na compreensão semântica e contextual das traduções, essenciais para uma aplicação prática no meio jurídico.

4.3 Visões da arquitetura e diagramas

Nesta seção, apresentaremos as visões da arquitetura do sistema e os diagramas na linguagem visual *Unified Modeling Language* (UML). A UML é uma linguagem padrão para especificação, visualização e documentação de sistemas de software, especialmente útil em projetos.

4.3.1 Visão de requisitos

Esta seção descreve os principais requisitos que impactam a arquitetura da aplicação, como a *Application Programming Interface* (API), linguagens de programação, *Frameworks* (estruturas) para o algoritmo de *Machine Learning* (ML) e bibliotecas.

Requisitos

- **Linguagem:** A aplicação será desenvolvida em Python, devido ao suporte extenso para bibliotecas de NLP, e ferramentas de aprendizado de máquina com TensorFlow e PyTorch.
- **Plataforma:** A API será implementada sobre uma plataforma de servidor de aplicações como o Flask, facilitando o desenvolvimento de *endpoints* RESTful para coleta de dados e consulta ao modelo de tradução.
- **Persistência:** Será adotada uma base de dados relacional (MySQL) para armazenamento de metadados dos documentos e um banco de dados NoSQL (MongoDB) para armazenamento dos documentos em si.

4.3.2 Visão de implantação

O diagrama de implantação (Figura 2) irá mostrar como os componentes físicos do sistema estão conectados e implantados no ambiente. Este diagrama incluirá a API, o serviço de NLP, o banco de dados para persistência, a API do Google Translate para medida de comparação com uma MT comum, e a interface de avaliação.




Figura 2 – Diagrama de Implantação do Sistema de Tradução Automática

4.3.3 Visão lógica

Esse diagrama (Figura 3) representa os componentes internos e suas responsabilidades, abordando a estrutura organizacional e as interdependências entre os subsistemas principais: o Serviço de NLP, o Serviço de Avaliação, e os Bancos de Dados.




Figura 3 – Diagrama de Classes do Sistema de Tradução Automática

5 Conclusão

Este trabalho apresenta uma proposta de sistema de tradução automática voltado para documentos jurídicos, utilizando técnicas de Processamento de Linguagem Natural (NLP) para capturar nuances culturais e legais entre o português e o inglês. A partir da análise do contexto jurídico e dos desafios da tradução, identifica-se que muitos termos e expressões legais requerem uma interpretação cuidadosa que vai além de uma tradução literal, reforçando a relevância de métodos avançados como modelos de aprendizado profundo.

O desenvolvimento do sistema inclui etapas de coleta e pré-processamento de dados, modelagem do modelo de tradução e avaliação da eficácia do sistema. Com isso, busca-se criar uma solução que auxilie na interpretação e disseminação de documentos jurídicos brasileiros em um contexto global, tornando essas informações mais acessíveis e compreensíveis para um público diversificado.

Os resultados, tanto quantitativos (como a métrica BLEU) quanto qualitativos (a partir da avaliação de profissionais da área jurídica), indicam que o sistema realiza traduções mais adequadas e contextualizadas em comparação com ferramentas de tradução convencionais. A adesão a um banco de dados ontologicamente estruturado mostra-se essencial para a compreensão semântica, proporcionando uma base sólida para as traduções jurídicas automatizadas.

Por fim, este trabalho contribui para a área de tradução automática ao explorar uma aplicação específica e complexa, como o contexto jurídico, sugerindo que o uso de tecnologias baseadas em NLP aprimora a precisão e a relevância das traduções em documentos especializados. Futuras pesquisas podem explorar a inclusão de outros idiomas e o refinamento dos modelos, além de investigar novas métricas de avaliação para capturar aspectos mais subjetivos presentes nas traduções legais.

Referências

- CALLISON-BURCH, C.; OSBORNE, M.; KOEHN, P. Re-evaluating the role of bleu in machine translation research. In: *11th conference of the european chapter of the association for computational linguistics*. 2006. p. 249–256. Citado na página 25.
- CHÁVEZ, E. L. New mexico’s success with non-english speaking jurors. *J. Ct. Innovation*, v. 1, p. 303–303, 2008. Citado na página 22.
- CHÉRAGUI, M. A. Theoretical overview of machine translation. *ICWIT*, Citeseer, p. 160–169, 2012. Citado 3 vezes nas páginas 21, 22 e 24.
- FOSTER, T. J.; NORTHROP, S. A. A lawyer’s guide to source code discovery. *The Federal Lawyer*, p. 42–46, 2011. Citado na página 23.
- NELSON, S. D.; SIMEK, J. W. Running with the machines: Ai in the practice of law. *Law Prac.*, HeinOnline, v. 43, p. 24, 2017. Citado na página 23.
- SOMERS, H. The use of machine translation by law librarians-a reply to yates. *Law Libr. J.*, HeinOnline, v. 99, p. 611, 2007. Citado na página 25.
- VIEIRA, L. N.; O’HAGAN, M.; O’SULLIVAN, C. Understanding the societal impacts of machine translation: a critical review of the literature on medical and legal use cases. *Information, Communication & Society*, Routledge, v. 24, n. 11, p. 1515–1532, 2021. Available on: <<https://doi.org/10.1080/1369118X.2020.1776370>>. Citado 4 vezes nas páginas 22, 23, 24 e 25.
- WAHLER, M. E. A word is worth a thousand words: Legal implications of relying on machine translation technology. *Stetson L. Rev.*, HeinOnline, v. 48, p. 109, 2018. Citado na página 25.